

**VIỆN HÀN LÂM KHOA HỌC VÀ CÔNG NGHỆ VIỆT NAM**  
**HỌC VIỆN KHOA HỌC VÀ CÔNG NGHỆ**



**BÁO CÁO BÀI TIỂU LUẬN HỌC PHẦN THẠC SĨ**  
**HỆ HỖ TRỢ QUYẾT ĐỊNH TIỀN TIẾN**

**Nội dung:**

**Phương pháp thực tiễn để chẩn đoán sớm bệnh tim  
thông qua mạng nơ ron sâu**

**Học viên thực hiện** : Phạm Văn Hiệp  
**Giảng viên** : TS. Vũ Văn Hiệu  
**Khoa** : CNTT & Viễn Thông  
**Lớp** : ITT2022B

Hà Nội – 2023

**PHIẾU CHẤM ĐIỂM**

Học viên thực hiện:

Họ và tên	Chữ ký	Ghi chú
Phạm Văn Hiệp		

**Giảng viên chấm:**

Họ và tên	Điểm	Chữ ký
Giảng viên chấm 1:		
Giảng viên chấm 2:		

## 1 Giới thiệu

Ngày nay, phần lớn những cái chết của con người là do bệnh tim. Vì lý do này, nhiều nghiên cứu đã được thực hiện để cải thiện việc chẩn đoán sớm bệnh tim và giảm tử vong. Những nghiên cứu này chủ yếu nhằm mục đích phát triển các hệ thống chẩn đoán có sự hỗ trợ của máy tính bằng cách sử dụng công nghệ đang phát triển. Một số hệ thống hỗ trợ máy tính là hệ thống hỗ trợ quyết định lâm sàng được phát triển để phát hiện bệnh tim dễ dàng hơn so với tiếng tim hoặc dữ liệu liên quan. Các hệ thống này là phần mềm được sử dụng trong chẩn đoán tự động các bệnh tim, thường dựa trên việc phân loại dữ liệu. Hầu hết các nghiên cứu được sử dụng để chẩn đoán bệnh tim nhằm tăng khả năng thành công của việc phân loại [1, 2].

Bathia và các đồng nghiệp đã phát triển một hệ thống hỗ trợ ra quyết định để phân loại bệnh tim bằng cách sử dụng support vector machine và thuật toán di truyền được mã hóa theo giá trị số nguyên. Trong nghiên cứu này, thuật toán di truyền được sử dụng để tối đa hóa hiệu suất của support vector machine đơn giản, chọn các thuộc tính phù hợp và xóa các thuộc tính không cần thiết [3]. Parthibane và Subramanian đã đề xuất một phương pháp dựa trên hệ suy luận mạng nơ ron mờ đồng tác động (CANFIS) để dự đoán bệnh tim. Mô hình CANFIS này đã kết hợp cách tiếp cận định tính với logic mờ được tích hợp với thuật toán di truyền để chẩn đoán khả năng của mạng lưới thần kinh và sau đó là sự hiện diện của bệnh [4].

Có rất nhiều dữ liệu trong các hệ thống y tế. Tuy nhiên, cần có các công cụ phân tích hiệu quả để khám phá các mối quan hệ và xu hướng tiềm ẩn trong dữ liệu. Với mục đích này, việc khám phá thông tin và sử dụng khai thác dữ liệu là những chủ đề quan trọng nhất trong các nghiên cứu khoa học. Các nhà nghiên cứu từ lâu đã sử dụng các kỹ thuật khai thác dữ liệu và thống kê để tạo ra kết

quả tốt hơn cho việc phân tích dữ liệu trong các tập dữ liệu lớn. Chẩn đoán bệnh là một trong những ứng dụng được thực hiện rộng rãi trong đó các kỹ thuật khai thác dữ liệu đã đạt được kết quả thành công. Ahmed và Hannan trong nghiên cứu của mình, họ đã thử nghiệm để tìm ra các bệnh tim bằng khai thác dữ liệu, support vector machine, Thuật toán di truyền, lý thuyết tập hợp thô, quy tắc hợp nhất và Mạng nơ ron nhân tạo. Họ đã phát hiện ra rằng cây quyết định và SVM có hiệu quả nhất đối với bệnh tim.

Do đó, họ tuyên bố rằng khai thác dữ liệu có thể giúp xác định hoặc dự đoán rủi ro cao hay thấp của bệnh tim [5]. Một nghiên cứu khai thác dữ liệu khác đã phân tích các hệ thống dự đoán bệnh Tim bằng cách sử dụng nhiều đặc điểm đầu vào hơn. Các kỹ thuật phân loại khai thác dữ liệu như NaiveBayes, Cây quyết định và cả Mạng nơ ron nhân tạo được đánh giá trên cơ sở dữ liệu bệnh tim.

Hiệu suất chung của các kỹ thuật liên quan này được so sánh và tương ứng, tỷ lệ chính xác phân loại của Mạng nơ-ron nhân tạo, Cây quyết định và Naive Bayes là cao [6]. Như chúng ta đã thấy, Mạng nơ-ron nhân tạo đã được sử dụng rộng rãi để chẩn đoán bệnh tim. Các công việc liên quan của Das và các cộng sự. [7] và công trình của Deperlioglu cũng là những ví dụ về các nghiên cứu gần đây [2].

Gần đây, các phương pháp học sâu cũng được sử dụng để phân loại tiếng tim. Ví dụ, Potes và các đồng nghiệp đã đề xuất một phương pháp dựa trên nhóm phân loại kết hợp các đầu ra của AdaBoost và Mạng nơ ron chuyển đổi (CNN) để thực hiện phân loại liên quan đến tiếng tim bình thường/bất thường [8]. Rubin và cộng sự. đã đề xuất một thuật toán phân loại âm thanh tim tự động cho phép kết hợp các chỉ báo bản đồ nhiệt tần số thời gian với CNN [9]. Deperlioglu trong các nghiên cứu của mình đã sử dụng CNN để phân loại ghi âm tâm đồ phân đoạn và không phân đoạn trong nghiên cứu của họ [10, 11].

Như có thể thấy từ các ví dụ trên, các phương pháp hỗn hợp phức tạp thường được sử dụng trong chẩn đoán bệnh tim để tăng khả năng phân loại thành công. Trong chương này, chúng tôi đã xem xét việc sử dụng phương pháp học sâu để tăng khả năng chẩn đoán bệnh tim thành công (không cần xử lý các phương pháp hoặc thuật toán phức tạp hơn). Chương này sẽ tập trung ngắn gọn vào việc phát hiện các bệnh tim bằng cách sử dụng bộ dữ liệu Bệnh tim Cleveland và Autoencoder Neural Networks (AEN). Ngoài ra, chương này là để chỉ ra rằng thành công phân loại có thể được tăng lên dễ dàng bằng cách sử dụng (AEN) mà không cần bất kỳ quá trình lựa chọn tính năng hoặc phương pháp hỗn hợp nào.

## **2 Nguyên tắc cơ bản**

Trong chương này, người ta đã giải thích rằng việc xác định các bệnh tim bằng cách sử dụng bộ dữ liệu Bệnh tim Cleveland và AEN có thể được phân loại dễ dàng mà không cần bất kỳ quy trình lựa chọn đặc điểm hoặc phương pháp hỗn hợp nào. Vật liệu và phương pháp được sử dụng cho nghiên cứu được đưa ra chi tiết dưới đây.

### **2.1 Bộ dữ liệu bệnh tim Cleveland**

Để thử nghiệm phương pháp được đề xuất, Cơ sở dữ liệu Tim mạch Cleveland được lấy từ kho lưu trữ tập dữ liệu học tập của UCI đã được sử dụng [12–15]. Cơ sở dữ liệu Bệnh Tim Cleveland bao gồm 303 bản ghi với 13 thuộc tính. Các thuộc tính này được đưa ra trong Bảng 6.1.

Hầu như tất cả các nghiên cứu được thực hiện để chẩn đoán bệnh tim với cơ sở dữ liệu này đều sử dụng 13 thuộc tính nêu trên làm đầu vào [6]. Dữ liệu trong bộ dữ liệu bao gồm 5 loại đầu ra, 1, 2, 3, 4 biểu thị sự hiện diện của bệnh tim và 0 biểu thị sự vắng mặt.

*Bảng 6.1 Định nghĩa 13 thuộc tính đầu vào*

No.	Attribute	Definition	Value(s)
1	Age	Age (as year)	Real (number)
2	Sex	Female or Male	0 = female/1 = male
3	CP	Type of chest pain	4 = asymptomatic 3 = non-agina pain 2 = typical type agina 1 = typical type 1
4	Thestbps	Pressure of resting blood	Real (number) value/mm hg
5	Chol	Serum cholesterol	Real (number) value/mm/dl
6	Restecg	Electrographic results in the context of resting	0 = normal 1 = having_ST_T wave abnormal 2 = left ventricular hypertrophy
7	Fbs	Sugar in fasting blood	$1 \geq 120$ mg/dl $0 \leq 120$ mg/dl
8	Thalach	Max. value of the heart rate	Real (number) value
9	Exang	Exercise induced agina	0 = no 1 = yes
10	Oldpeak	ST depression state as induced by exercise relative to rest	Real (number) value
11	Solpe	Slope of the peak exercise ST segment	3 = downsloping 2 = flat 1 = unsloping
12	CA	As colored by flour sopy, number of major vessels	value within 0-3
13	Thal	Type of defect	7 = reversible defect 6 = fixed 3 = normal


## **2.2 Autoencoder Neural Network**

Autoencoder Neural Networks lần đầu tiên đư ợc giới thiệu bởi Hinton và Salakhutdinov vào năm 2006 [16]. Về cơ bản, nó có thể đư ợc coi là mạng nơ ron chuyển tiếp nguồn cấp dữ liệu đư ợc đào tạo để trở thành bản sao đáng tin cậy của đầu vào. Nhưng mô hình mạng đư ợc cấu trúc sao cho các lớp trung gian sử dụng ít nơ-ron hơn so với các lớp cấp trên và cấp dưới. Do đó, mạng có thể đư ợccoại là một cặp bộ mã hóa-giải mã đư ợc liên kết với số lư ợng nơ-ron ít nhất chứa biểu diễn đư ợc mã hóa của các đầu vào. Bởi vì mỗi lớp chỉ phụ thuộc vào các giá trị của lớp trư ớc đó, kiến thức về mã hóa là đủ để tính toán sự tái tạo tư ơng ứng [17]. Thông

thường, các mạng mã hóa tự động được xác định bằng cách đặt số lượng nút trong mỗi lớp. Hình 6.1 cho thấy kiến trúc mô hình của mạng Autencoder.

Các lớp nút liên tiếp phát hiện các mẫu trong dữ liệu đầu vào và sử dụng chúng để tạo biểu diễn dữ liệu được mã hóa. Nó nhận mã hóa bộ giải mã tương ứng và cố gắng cấu hình lại các mục ban đầu. Thuật toán đào tạo mạng liên quan đến việc điều chỉnh hành vi của từng nút để đưa các cấu hình đến gần dữ liệu hơn. Mạng có thể được xác định theo số nút trong mỗi lớp. Ví dụ, mạng được hiển thị trong Hình 6.1 Có năm lớp nút được kết nối với nhau bởi bốn lớp nơ-ron và là 7-6-4-6-7 AutenCoder [17].

Các bộ mã hóa tự động thuộc về thuật toán học theo lớp được gọi là học không giám sát và thuật toán học không kiểm tra không cần thông tin được gắn thẻ cho dữ liệu [18].



Hình 1 : Kiến trúc của Autoencoder Neural Network

### 2.3 Đánh giá hoạt động

Độ chính xác, độ nhạy và độ đặc hiệu là các thước đo hiệu suất thường được sử dụng trong các nghiên cứu phân loại y tế. Các biện pháp này được sử dụng để đánh giá độ chính xác của phương pháp đề xuất. Chúng được tính như sau:

$$Ac = \frac{T_P}{T_P + F_P} \quad (6.1)$$

$$Se = \frac{T_P}{T_P + F_N} \quad (6.2)$$

$$Sp = \frac{T_N}{F_{PTN} + T_N} \quad (6.3)$$

Trong các phương trình,  $T_P$  và  $F_P$  đại diện cho các số tương ứng cho kết quả dương tính thật và kết quả dương tính giả. Mặt khác,  $T_P$  và  $F_P$  tương ứng với số lượng âm tính thực và âm tính giả.  $F_{PTN}$  cũng đại diện cho số lượng dương tính giả và nó được tính toán từ các mẫu âm tính trong kết quả phân loại.

Độ chính xác của khả năng chẩn đoán chính xác của bộ phân loại được xác định bởi tỷ lệ chính xác. Mức độ mà mô hình xác định chính xác sự hình thành của lớp mục tiêu được xác định bởi tỷ lệ độ nhạy. Mức độ khả năng phân tách lớp mục tiêu của mô hình được xác định bởi tỷ lệ Độ đặc hiệu [10].

## 3 Chẩn đoán sớm bệnh tim

Khi kết thúc một số lượng lớn các thử nghiệm với bộ dữ liệu cơ sở dữ liệu Tim mạch Cleveland, các thông số của AEN đã thu được. Cấu trúc và Chi tiết của AEN, bao gồm tổng cộng 8 giai đoạn, được đưa ra trong Hình 6.2.



Trong nghiên cứu phân loại với AEN, Có 24 lớp ẩn trong mạng. Trong giai đoạn mã hóa, thang đo được sử dụng như một thuật toán tỷ lệ và chức năng của hàm chi phí entropy chéo được sử dụng. Trong giai đoạn giải mã, thuật toán Levenberg- Marquardt và phương pháp sai số bậc hai trung bình đã được sử dụng.

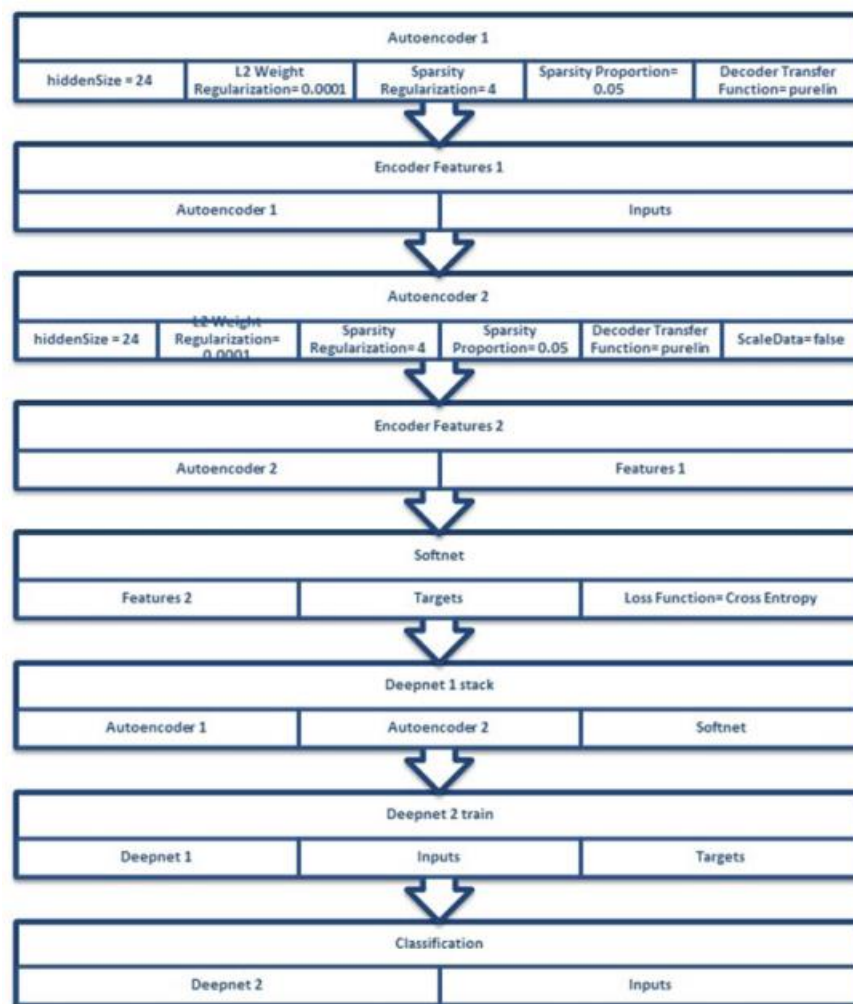
Với AEN thu được, 80% bộ dữ liệu và 20% dữ liệu được phân loại là dữ liệu thử nghiệm. Quá trình phân loại và dữ liệu huấn luyện và kiểm tra khác nhau được chọn ngẫu nhiên, được lặp lại 20 lần. Tỷ lệ về độ chính xác, độ nhạy và độ đặc hiệu (như thu được trong các nghiên cứu này) được tính trung bình. Kết quả của các thí nghiệm, ma trận nhầm lẫn cho tỷ lệ chính xác thấp nhất và cao nhất được đưa ra trong Hình. 6.3 và 6.4 tương ứng.

Kết thúc 20 thử nghiệm, tỷ lệ chính xác trung bình là 99,13%, độ nhạy là 97,90%, và độ đặc hiệu là 97,95%.

Để đánh giá hiệu suất của phương pháp được đề xuất, phương pháp được so sánh với kết quả của các nghiên cứu trước đây sử dụng cùng một bộ dữ liệu. Đó là: (1) Deperlioglu đã sử dụng mạng thần kinh nhân tạo (ANN) với thuật toán điều chỉnh Bayesian [1]. (2)

Bathia và những người khác đã sử dụng thuật toán di truyền (GA) để lựa chọn các tính năng và support vector machine (SSVM) để phân loại [3]. (3) Kahramanli và Allahverdi đã sử dụng phương pháp lai bao gồm mạng nơ ron nhân tạo (ANN) và mạng nơ ron mờ (FNN) [21]. (4) Anooj sử dụng luật mờ có trọng số (WFR). (5) Das và cộng sự đã sử dụng phương pháp tập hợp mạng nơ-ron (ANN) [7]. (6) Setiawan và Cộng Sự. đã sử dụng hệ hỗ trợ quyết định mờ (FDSS) với phương pháp rút trích luật dựa trên lý thuyết tập thô [20]. (7)–(9) Họ cũng sử dụng phương pháp perceptron ANN (MLP ANN), k Nearest Neighbor (k-NN), C4.5 và RIPPER để so Sánh[20 ]. (10)

Chi tiết được đưa ra trong Bảng 6.2. Các giá trị cao nhất trong bảng được in đậm. Như có thể hiểu từ Bảng 6.2, phương pháp đề xuất cho kết quả tốt hơn so với nhiều phương pháp đơn lẻ hoặc kết hợp. Tỷ lệ chính xác 99,13% cho thấy độ chính xác của khả năng chẩn đoán chính xác của bộ phân loại là cao. Tỷ lệ độ nhạy trong 97,90% cho thấy mô hình có mức độ xác định chính xác cao của sự hình thành lớp mục tiêu. Tỷ lệ độ đặc hiệu 97,95% chỉ ra rằng mô hình có phạm vi khả năng phân tách lớp mục tiêu rộng.



Hình 2 : Cấu trúc và chi tiết của Autoencoder neural network

## 4. Kết quả và thảo luận

Nhiều hệ thống hỗ trợ quyết định y sinh đã được phát triển để giảm tử vong sớm do bệnh tim bằng cách phát triển chẩn đoán sớm. Các nhà nghiên cứu đã cố gắng tăng hiệu quả với các phương pháp hỗn hợp bằng cách sử dụng các phương pháp khác nhau như phương pháp tối ưu hóa cùng với kỹ thuật phân loại. Trong nghiên cứu này, người ta giải thích rằng độ chính xác của phân loại có thể được tăng lên bằng cách sử dụng Autoencoder neural network từ các mạng nơ ron sâu mà không sử dụng các phương pháp hỗn hợp hoặc lựa chọn tính năng với các phương pháp tối ưu hóa khác nhau. Với mục đích này, bộ dữ liệu Bệnh tim Cleveland, được sử dụng rộng rãi trong cơ sở dữ liệu y tế tại phòng thí nghiệm máy học của Đại học California Irvine (UCI), đã được sử dụng. Các giá trị độ chính xác, độ nhạy và độ đặc hiệu thu được bằng phương pháp đề xuất cho thấy phương pháp có hiệu suất cao. Do đó, với khối lượng công việc ít hơn nhiều, bệnh tim có thể được chẩn đoán trong thời gian ngắn hơn.

Confusion Matrix						
Output Class	1	2	3	4	5	
	161 53.1%	0 0.0%	0 0.0%	0 0.0%	0 0.0%	100% 0.0%
	1 0.3%	55 18.2%	0 0.0%	0 0.0%	0 0.0%	98.2% 1.8%
	0 0.0%	0 0.0%	37 12.2%	0 0.0%	0 0.0%	100% 0.0%
	2 0.7%	0 0.0%	0 0.0%	34 11.2%	0 0.0%	94.4% 5.6%
	1 0.3%	0 0.0%	0 0.0%	0 0.0%	12 4.0%	92.3% 7.7%
	97.6% 2.4%	100% 0.0%	100% 0.0%	100% 0.0%	100% 0.0%	98.7% 1.3%
Target Class						
1	2	3	4	5		

Hình 3 : Ma trận nhầm lẫn cho tỷ lệ chính xác thấp nhất

## 5. Tóm tắt

Vì phần lớn các trường hợp tử vong ở người là do bệnh tim, nhiều nghiên cứu thay thế đã được thực hiện để cải thiện việc chẩn đoán sớm bệnh tim và giảm tử vong.

**Confusion Matrix**

Output Class	1	2	3	4	5	
1	163 53.8%	0 0.0%	0 0.0%	0 0.0%	0 0.0%	100% 0.0%
2	1 0.3%	55 18.2%	0 0.0%	0 0.0%	0 0.0%	98.2% 1.8%
3	0 0.0%	0 0.0%	37 12.2%	0 0.0%	0 0.0%	100% 0.0%
4	1 0.3%	0 0.0%	0 0.0%	34 11.2%	0 0.0%	97.1% 2.9%
5	0 0.0%	0 0.0%	0 0.0%	0 0.0%	12 4.0%	100% 0.0%
	98.8% 1.2%	100% 0.0%	100% 0.0%	100% 0.0%	100% 0.0%	99.3% 0.7%
	1	2	3	4	5	Target Class

Hình 4 : Ma trận nhầm lẫn cho tỉ lệ chính xác cao nhất

Những nghiên cứu này chủ yếu nhằm mục đích phát triển các hệ thống chẩn đoán hỗ trợ của máy tính. Sử dụng công nghệ đang phát triển. Một số hệ thống hỗ trợ máy tính là hệ thống hỗ trợ quyết định lâm sàng được phát triển để phát hiện bệnh tim dễ dàng hơn so với tiếng tim hoặc dữ liệu liên quan. Các hệ thống này là

phần mềm được sử dụng trong chẩn đoán tự động các bệnh tim, thường dựa trên việc phân loại dữ liệu. Tại thời điểm này, các kỹ thuật học sâu đã đưa mức độ thành công lên các giá trị cao hơn nhờ khả năng phân tích và chẩn đoán chuyên sâu của chúng.

Trong chương này, một nghiên cứu phân loại với AEN đã được giới thiệu tương ứng, như một công cụ dễ sử dụng để chẩn đoán bệnh tim. Khi được cấu trúc trên 24 lớp ẩn hình thành trong mạng, thang đo được sử dụng làm thuật toán tỷ lệ và chức năng của hàm chi phí entropy chéo được sử dụng để đào tạo hiệu quả. Trong giai đoạn giải mã, thuật toán Levenberg-Marquardt và phương pháp sai số bậc hai trung bình cũng được sử dụng. AEN được đào tạo bởi 80% bộ dữ liệu và 20% dữ liệu dưới dạng thử nghiệm, thông qua dữ liệu thử nghiệm và đào tạo khác nhau được chọn ngẫu nhiên và quá trình phân loại được lặp lại 20 lần. Tỷ lệ chính xác trung bình là 99,13% trong khi độ nhạy là 97,90% và độ đặc hiệu là 97,95%. Giải pháp AEN ở đây cũng được so sánh với tài liệu và thấy rằng nó cho kết quả tốt hơn nhiều phương pháp đơn lẻ hoặc kết hợp. Tỷ lệ chính xác 99,13% của AEN cho thấy độ chính xác của khả năng chẩn đoán chính xác của bộ phân loại là cao. Với độ nhạy tỷ lệ trong 97,90%, nó cũng có mức độ xác định chính xác cao về sự hình thành của lớp mục tiêu và nó cũng có khả năng phân tách lớp mục tiêu trên phạm vi rộng, xem xét tỷ lệ độ đặc hiệu là 97,95%.

*Bảng 2 : dữ liệu so sánh của các nghiên cứu trước sử dụng cùng bộ dữ liệu*

Order of study	Author	Method	Accuracy (%)	Sensitivity (%)	Specificity (%)
1	This study	AEN	<b>99.13</b>	<b>97.90</b>	<b>97.95</b>
2	Deperlioglu [1]	ANN	85.8	86.7	86.7
3	Bhatia et al. [3]	GA + SSVM	86.50	86.3	88.50
4	Kahramanli [5]	ANN + FNN	87.40	93	78.5
5	Anooj [19]	WFR	62.35	76.59	44.73
6	Das et al. [7]	ANN	89.01	80.95	95.91
7	Setiawan [20]	FDSS	81.00	83.00	85.00
8	Setiawan [20]	MLP-ANN	81.00	77.85	85.00
9	Setiawan [20]	k-NN	81.00	84.00	79.00
10	Setiawan [20]	C4.5	82.00	79.00	85.00
11	Setiawan [20]	RIPPER	83.00	82.00	84.00

Ngươi ta thấy rằng có thể hình thành một mô hình chẩn đoán dễ sử dụng và thậm chí dễ xây dựng với học sâu mà không cần bất kỳ cấu trúc lai phức tạp nào hoặc các quy trình tiền xử lý và phân loại chi tiết. Ở đây, một ví dụ về việc sử dụng AEN cho mục đích đã được hiển thị.

Vì bản thân học sâu có thể đủ hiệu quả để giải quyết các vấn đề y tế mục tiêu, nên nó vẫn có thể mở ra để phát triển các giải pháp kết hợp vì một số vấn đề có thể yêu cầu sự hợp tác tiên tiến hơn của các kỹ thuật khác nhau. Tương tự như các kỹ thuật học máy truyền thống, luôn có thể hình thành mối quan hệ chặt chẽ giữa trí thông minh bầy đàn và học sâu. Vì vậy, chấp tiếp theo7 cung cấp một cách tiếp cận ví dụ để đảm bảo hệ thống chẩn đoán đa bệnh.

## **6. Đọc thêm**

Để tìm hiểu thêm về các ứng dụng đáng chú ý của trí tuệ nhân tạo trong chẩn đoán bệnh tim, độc giả có thể tham khảo [22–30].

Trong tài liệu, cũng có thể thấy việc sử dụng các kỹ thuật học sâu thay thế để chẩn đoán bệnh tim. Đối với một số tác phẩm rất gần đây theo cách này, độc giả có thể đọc [31–37].

Cũng như đau tim có một vị trí quan trọng trong số tất cả các bệnh tim, bạn có thể đọc thêm một số công trình nghiên cứu đáng chú ý về trí tuệ nhân tạo (máy/học sâu) từ [38–43].

### Tài liệu tham khảo

1. O. Deperlioglu, The effects of different training algorithms on the classification of medical databases using artificial neural networks, in *European Conference on Science, Art & Culture ECSAC* (2018)
2. Ömer Deperlioglu, Classification of segmented heart sounds with Artificial Neural Networks. *Int. J. Appl. Math. Electr. Comput.* **6**(4), 39–44 (2018)
3. S. Bhatia, P. Prakash, G.N. Pillai, SVM based decision support system for heart disease classification with integer-coded genetic algorithm to select critical features, in *Proceedings of the World Congress on Engineering and Computer Science* (2008)
4. L. Parthiban, R. Subramanian, Intelligent heart disease prediction system using CANFIS and genetic algorithm. *Int. J. Biol. Biomed. Med. Sci.* **3**(3) (2008)
5. A. Ahmed, S.A. Hannan, Data mining techniques to find out heart diseases: an overview. *Int. J. Innov. Technol. Explor. Eng. (IJITEE)*, **1**(4) (2012). ISSN 2278-3075
6. C.S. Dangare, S. Apte Sulabha, Improved study of heart disease prediction system using data mining classification techniques, *Int. J. Comput. Appl.* **47**(10), 44–48 (2012)
7. Resul Das, Ibrahim Turkoglu, Abdulkadir Sengur, Effective diagnosis of heart disease through neural networks ensembles. *Expert Syst. Appl.* **36**(4), 7675–7680 (2009)
8. C. Potes, S. Parvaneh, A. Rahman, B. Conroy, Ensemble of feature-based and deep learningbased classifiers for detection of abnormal heart sounds.  
<https://arxiv.org/pdf/1707.04642.pdf>.  
2017
9. J. Rubin, R. Abreu, A. Ganguli, S. Nelaturi, I. Matei, K. Sricharan, recognizing abnormal heart sounds using deep learning.  
<https://physionet.org/challenge/2016/papers/potes.pdf> (2017)
10. O. Deperlioglu, Classification of phonocardiograms by convolutional neural networks, *BRAIN. Broad Res. Artif. Intell. Neurosci.* **9**(2) (2018)
11. O. Deperlioglu, Classification of phonocardiograms by convolutional neural networks, *BRAIN. Broad Res. Artif. Intell. Neurosci.* **10**(1) (2019)
12. Cleveland heart disease data set.  
<http://archive.ics.uci.edu/ml/datasets/Heart+Disease>. Last  
Accessed 10 Jan 2019
13. Robert Detrano et al., International application of a new probability algorithm for the diagnosis of coronary artery disease. *Am. J. Cardiol.* **64**(5), 304–310 (1989)
14. D. Aha, D. Kibler, Instance-based prediction of heart-disease presence with the Cleveland database. *Univ. Calif.* **3**(1), 3–2 (1988)
15. John H. Gennari, Pat Langley, Doug Fisher, Models of incremental concept



formation. *Artif. Intell.* **40**(1-3), 11–61 (1989)

16. G. Hinton, R. Salakhutdinov, Reducing the dimensionality of data with neural networks. *Science* **313**, 504–507 (2006)

17. Andrew P. Valentine, Trampert Jeannot, Data space reduction, quality assessment and searching of seismograms: autoencoder networks for waveform data. *Geophys. J. Int.* **189**(2), 1183–1202 (2012)

18. Q.V. Le, A tutorial on deep learning part 2: autoencoders, convolutional neural networks and recurrent neural networks. *Google Brain* 1–20 (2015)

References 105

19. P.K. Anooj, Clinical decision support system: Risk level prediction of heart disease using weighted fuzzy rules. *J. King Saud Univ.-Comput. Inf. Sci.* **24**(1), 27–40 (2012)

20. N.A. Setiawan, P.A. Venkatachalam, A.F.M. Hani, Diagnosis of coronary artery disease using artificial intelligence based decision support system, in *Proceedings of the International Conference on Man-Machine Systems (ICoMMS)* (Batu Ferringhi, Penang. 2009)

21. Humar Kahramanli, Novruz Allahverdi, Design of a hybrid system for the diabetes and heart diseases. *Expert Syst. Appl.* **35**(1-2), 82–89 (2008)

22. I. Abdel-Motaleb, R. Akula, Artificial intelligence algorithm for heart disease diagnosis using phonocardiogram signals, in *2012 IEEE International Conference on Electro/Information Technology* (IEEE, 2012), pp. 1–6

23. S. Ghumbre, C. Patil, A. Ghatol, Heart disease diagnosis using support vector machine, in *International Conference on Computer Science and Information Technology (ICCSIT') Pattaya* (2011)

24. G. Manogaran, R. Varatharajan, M.K. Priyan, Hybrid recommendation system for heart disease diagnosis based on multiple kernel learning with adaptive neuro-fuzzy inference system. *Multimedia Tools Appl.* **77**(4), 4379–4399 (2018)

25. H. Yan, Y. Jiang, J. Zheng, C. Peng, Q. Li, A multilayer perceptron-based medical decision support system for heart disease diagnosis. *Expert Syst. Appl.* **30**(2), 272–281 (2006)

26. A. Adeli, M. Neshat, A fuzzy expert system for heart disease diagnosis, in *Proceedings of International Multi Conference of Engineers and Computer Scientists, Hong Kong*, vol. 1 (2010), pp. 28–30

27. J. Nahar, T. Imam, K.S. Tickle, Y.P.P. Chen, Computational intelligence for heart disease diagnosis: A medical knowledge driven approach. *Expert Syst. Appl.* **40**(1), 96–104 (2013)

28. O.Y. Atkov, S.G. Gorokhova, A.G. Sboev, E.V. Generozov, E.V. Muraseyeva, S.Y. Moroshkina, N.N. Cherniy, Coronary heart disease diagnosis by artificial neural networks including genetic polymorphisms and clinical parameters. *J. Cardiol.* **59**(2), 190–194 (2012)

29. E.O. Olaniyi, O.K. Oyedotun, K. Adnan, Heart diseases diagnosis using neural networks arbitration. *Int. J. Intell. Syst. Appl.* **7**(12), 72 (2015)
30. M.G. Feshki, O.S. Shijani, Improving the heart disease diagnosis by evolutionary algorithm of PSO and feed forward neural network, in *2016 Artificial Intelligence and Robotics (IRANOPEN)* (IEEE 2016), pp. 48–53
31. S. Tuli, N. Basumatary, S.S. Gill, M. Kahani, R.C. Arya, G.S. Wander, R. Buyya, Healthfog: an ensemble deep learning based smart healthcare system for automatic diagnosis of heart diseases in integrated IoT and fog computing environments. *Future Gener. Comput. Syst.* **104**, 187–200 (2020)
32. K.K. Wong, G. Fortino, D. Abbott, Deep learning-based cardiovascular image diagnosis: a promising challenge. *Future Gener. Comput. Syst.* (2019)
33. R. Alizadehsani, M. Roshanzamir, M. Abdar, A. Beykikhoshk, A. Khosravi, M. Panahiazar, A. Koohestani, N. Sarrafzadegan, A database for using machine learning and data mining techniques for coronary artery disease diagnosis. *Sci. Data* **6**(1), 1–13 (2019)
34. N. Zhang, G. Yang, Z. Gao, C. Xu, Y. Zhang, R. Shi, J. Keegan, L. Xu, H. Zhang, Z. Fan, D. Firmin, Deep learning for diagnosis of chronic myocardial infarction on nonenhanced cardiac cine MRI. *Radiology* **291**(3), 606–617 (2019)
35. G.A. Tadesse, T. Zhu, Y. Liu, Y. Zhou, J. Chen, M. Tian, D. Clifton, Cardiovascular disease diagnosis using cross-domain transfer learning, in *2019 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)* (IEEE, 2019), pp. 4262–4265
36. A.Y. Hannun, P. Rajpurkar, M. Haghpanshi, G.H. Tison, C. Bourn, M.P. Turakhia, A.Y. Ng, Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. *Nat. Med.* **25**(1), 65 (2019)
37. A. Junejo, Y. Shen, A.A. Laghari, X. Zhang, H. Luo, Molecular diagnostic and using deep learning techniques for predict functional recovery of patients treated of cardiovascular disease. *IEEE Access* **7**, 120315–120325 (2019)
- 106 6 A Practical Method for Early Diagnosis of Heart Diseases ...
38. A. Bhardwaj, A. Kundra, B. Gandhi, S. Kumar, A. Rehalia, M. Gupta, Prediction of heart attack using machine learning. *IITM J. Manage. IT* **10**(1), 20–24 (2019)
39. B. Ballinger, B., Hsieh, J., Singh, A., Sohoni, N., Wang, J., Tison, G. H., ... & Pletcher, M. J. (2018). DeepHeart: semi-supervised sequence learning for cardiovascular risk prediction. In *Thirty-Second AAAI Conference on Artificial Intelligence*
40. A. Kishore, A. Kumar, K. Singh, M. Punia, Y. Hambir, Heart attack prediction using deep learning. *Heart* **5**(04) (2018)
41. S.B. Patil, Y.S. Kumaraswamy, Extraction of significant patterns from heart

disease warehouses for heart attack prediction. IJCSNS **9**(2), 228–235 (2009)

42. R. Chitra, V. Seenivasagam, Heart attack prediction system using fuzzy C means classifier. IOSR J. Comput. Eng. **14**, 23–31 (2013)

43. C. Thirumalai, A. Duba, R. Reddy, Decision making system using machine learning and Pearson for heart attack. In *2017 International Conference of Electronics, Communication and Aerospace Technology (ICECA)*, vol. 2 (IEEE, 2017), pp. 206–210